МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ

Київський Авіаційний Інститут
Факультет комп’ютерних наук та технологій
Кафедра аналітики даних та штучного інтелекту

ЛАБОРАТОРНА РОБОТА № 1

«Аналіз багатовимірних об’єктів спостережень: кореляційний, регресійний аналіз та метод головних компонент»

Дисципліна: «Аналіз даних»

Виконав: студент групи
ШІ-318
Шапран Олег
Перевірив:
Тупко Н.П.

Київ – 2026

1. Зміст

1. Зміст 2
2. Постановка задачі 3
3. Теоретичні відомості 4
   3.1. Кореляційний аналіз 4
   3.2. Метод головних компонент (МГК) 4
   3.3. Перевірка значущості 4
4. Структура програми 5
5. Приклад роботи програми 6
   5.1. Завантаження даних та видалення аномалій 6
   5.2. Кореляційний аналіз 6
   5.3. Метод головних компонент (МГК) 7
   5.4. Візуалізація (Гліфи та 3D моделі) 9
6. Висновки 11

2. Постановка задачі

Метою лабораторної роботи є розробка програмного забезпечення для комплексного аналізу багатовимірних статистичних даних. Основні завдання включають:

1. Реалізація первинного статистичного аналізу вибірки.
2. Проведення кореляційного аналізу (парна, часткова та множинна кореляції) з перевіркою статистичної значущості.
3. Побудова моделі множинної лінійної регресії.
4. Візуалізація багатовимірних даних (гліфи, 3D-поверхні, паралельні координати).
5. Реалізація методу головних компонент (МГК) для зниження розмірності та переходу до незалежної системи координат.

3. Теоретичні відомості

У роботі використано наступні статистичні методи:

3.1. Кореляційний аналіз

- **Парна кореляція (Пірсон):** вимірює тісноту лінійного зв’язку між двома змінними.
- **Часткова кореляція:** вимірює зв’язок між двома змінними при фіксованому зназі інших факторів.
- **Множинна кореляція:** характеризує сукупний вплив групи факторів на результат.

3.2. Метод головних компонент (МГК)

Метод базується на знаходженні власних чисел (λ) та власних векторів кореляційної матриці. Він дозволяє перейти від корельованих ознак до незалежних головних компонент, які впорядковані за часткою поясненої дисперсії.

3.3. Перевірка значущості

Для оцінки результатів використовуються:

- **t-критерій Стьюдента** (для парних та часткових кореляцій).
- **F-критерій Фішера** (для множинної кореляції та регресії).
- **p-value** — ймовірність отримання таких результатів за умови істинності нульової гіпотези.

4. Структура програми

Програма написана на мові Python з використанням бібліотек `Pandas`, `NumPy`, `SciPy` та `Matplotlib`. Графічний інтерфейс реалізований на `Tkinter`.

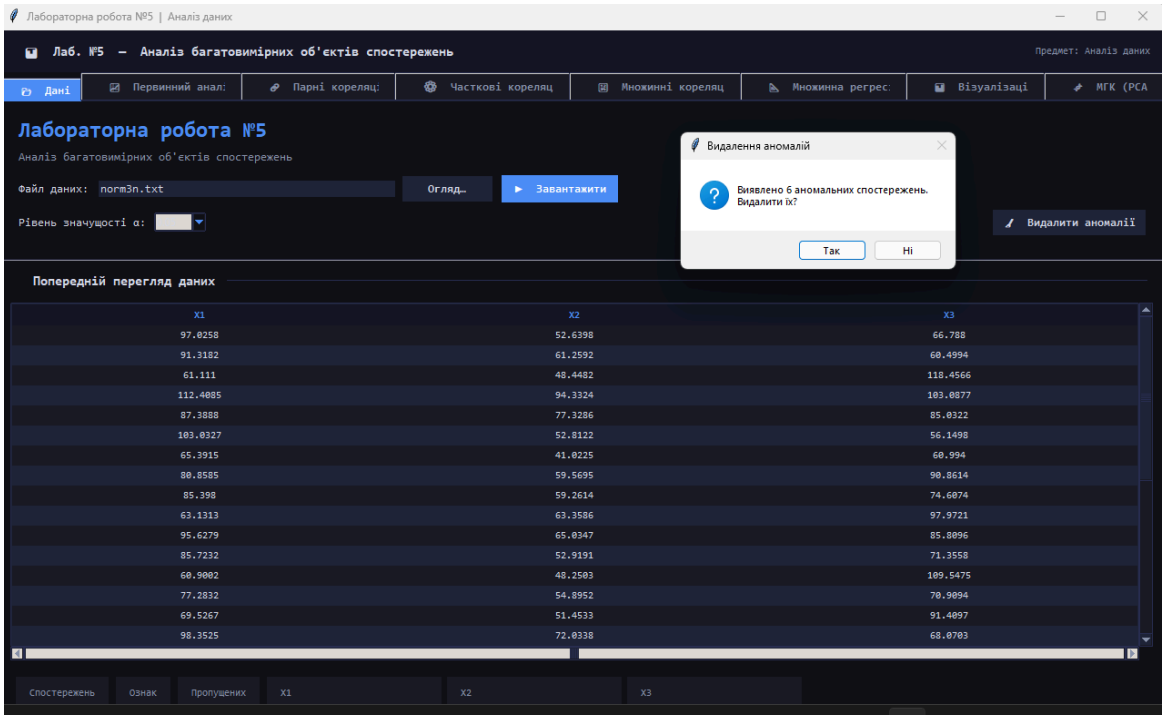
Модульна структура:

- `main.py` — головний файл, що керує інтерфейсом та вкладками.
- `stats_core.py` — обчислювальне ядро для кореляцій та первинної статистики.
- `stats_pca.py` — математична реалізація методу головних компонент.
- `stats_regression.py` — розрахунки параметрів регресійної моделі.
- `plots.py`, `plots_pca.py`, `plots_regression.py` — модулі для генерації складних графіків.

5. Приклад роботи програми

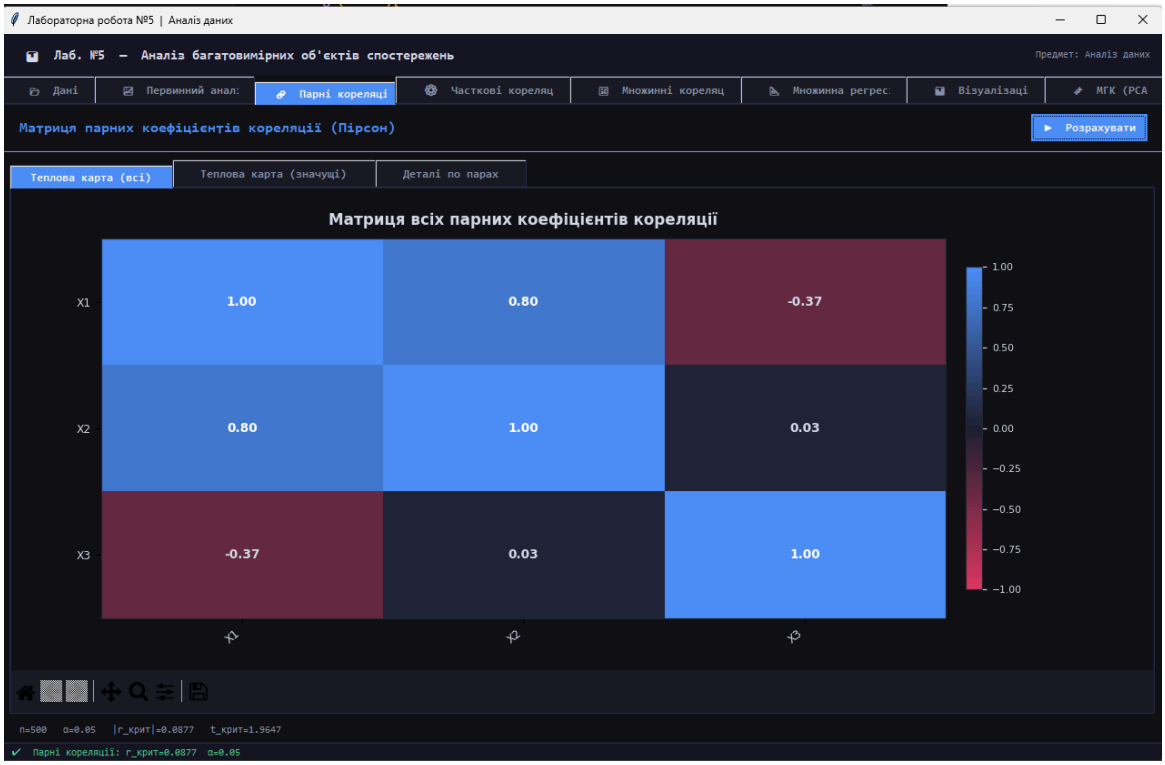
5.1. Завантаження даних та видалення аномалій

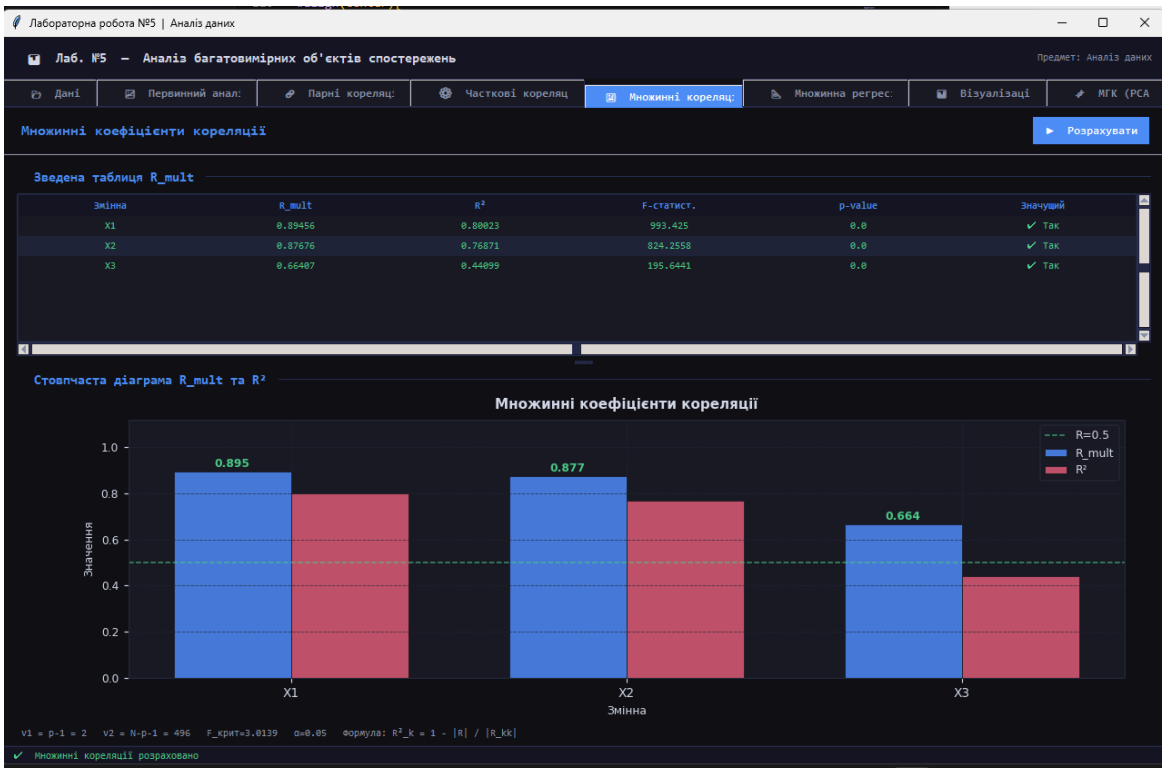
Додаток дозволяє імпортувати дані та проводити очистку від викидів за методом Z-score.



5.2. Кореляційний аналіз

Результати розрахунку парних, часткових та множинних кореляцій представлені у вигляді таблиць та теплових карт.

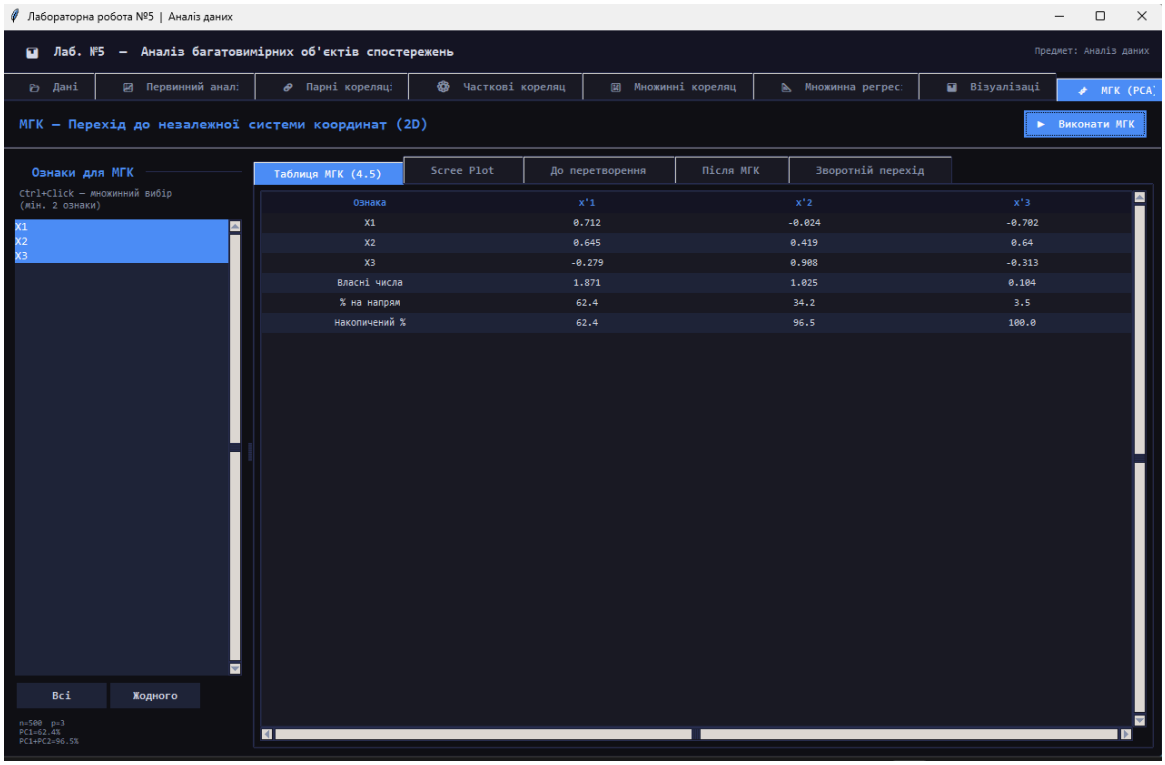


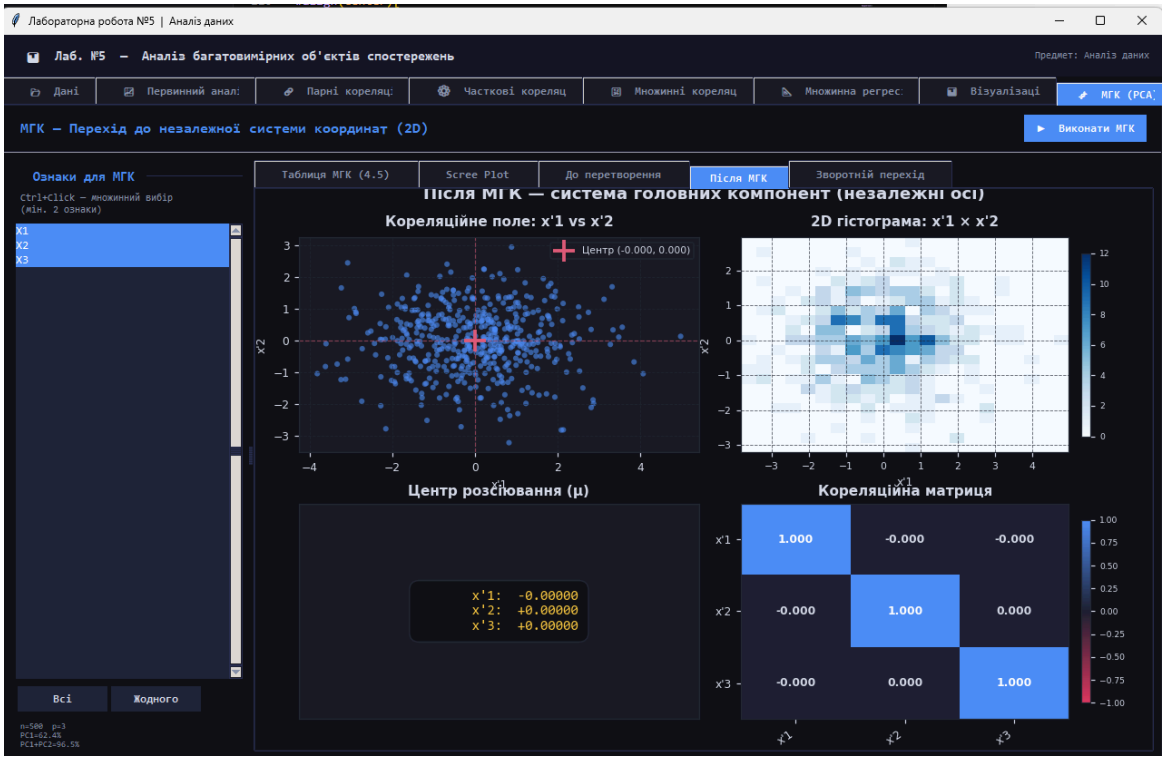


5.3. Метод головних компонент (МГК)

У вкладці МГК представлено таблицю факторних навантажень (аналог табл. 4.5) та порівняння просторів до і після перетворення.

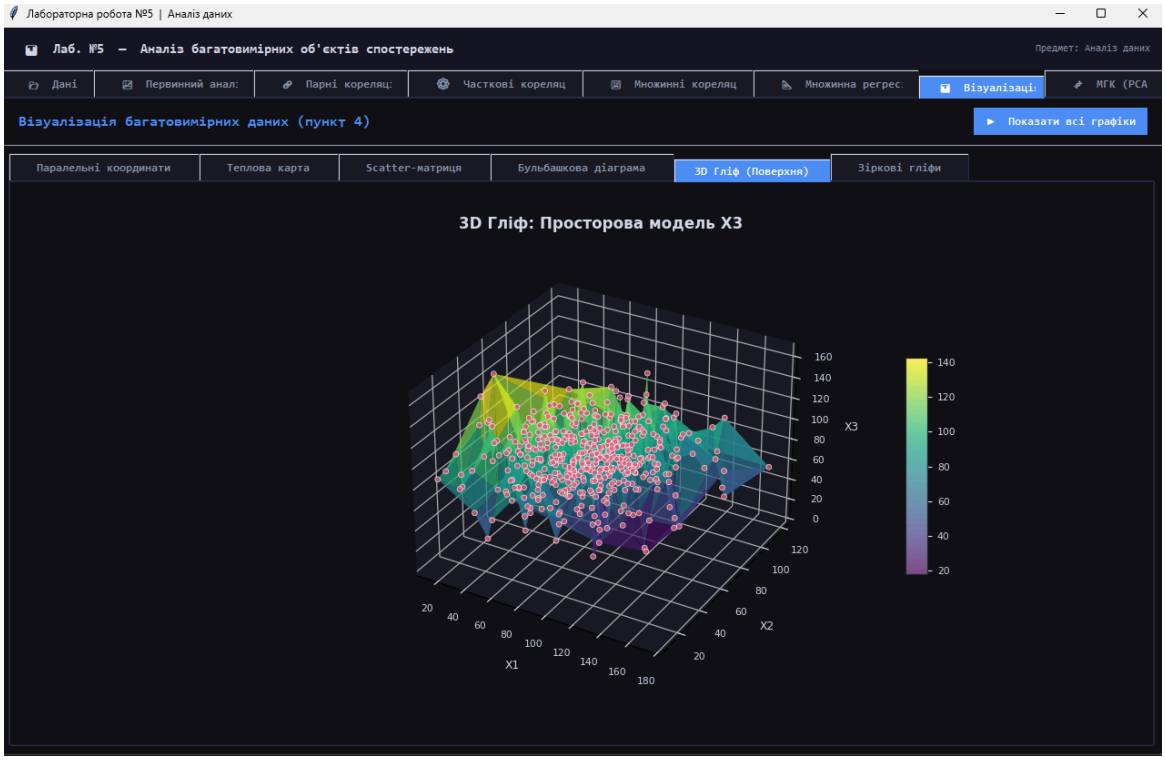

Лабораторна робота №5 | Аналіз даних
Лаб. №5 — Аналіз багатовимірних об'єктів спостережень
Предмет: Аналіз даних
Дані
Первинний анал:
Парні кореляц:
Часткові кореляц:
Множинні кореляц
Множинна регрес:
Візуалізації
МГК (PCA
Часткові коефіцієнти кореляції
Розрахувати
Таблиця деталей
Теплова карта
Матриця часткових коефіцієнтів кореляції
X1
X2
X3
1.00
0.88
-0.66
0.88
1.00
0.59
-0.66
0.59
1.00
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00
Forest Plot (ДІ)
Часткові коефіцієнти кореляції (forest plot)
Значущий (+ ДІ)
Незначущий
3 — X2
3 — X1
2 — X3
2 — X1
1 — X3
1 — X2
−1.00 −0.75 −0.50 −0.25 0.00 0.25 0.50 0.75 1.00
r часткова
Порядок w=1 df = N-w-2 = 497 t_крит=1.9647 α=0.05 (ДІ через перетворення Фішера, df_ДІ = N-w-3 = 496)
Часткові кореляції розраховано


Лабораторна робота №5 | Аналіз даних
Лаб. №5 — Аналіз багатовимірних об'єктів спостережень
Предмет: Аналіз даних
Дані
Первинний анал:
Парні кореляц:
Часткові кореляц
Множинні кореляц
Множинна регрес:
Візуалізації
МГК (PCA)
МГК — Перехід до незалежної системи координат (2D)
Виконати МГК
Ознаки для МГК
Ctrl+Click — множинний вибір
(мін. 2 ознаки)
X1
X2
X3
Всі
Жодного
n=500 p=3
PC1=62.4%
PC1+PC2=96.5%
Таблиця МГК (4.5)
Scree Plot
До перетворення
Після МГК
Зворотній перехід
Ознака x'1 x'2 x'3
X1 0.712 -0.024 -0.702
X2 0.645 0.419 0.64
X3 -0.279 0.908 -0.313
Власні числа 1.871 1.025 0.104
% на напрям 62.4 34.2 3.5
Накопичений % 62.4 96.5 100.0

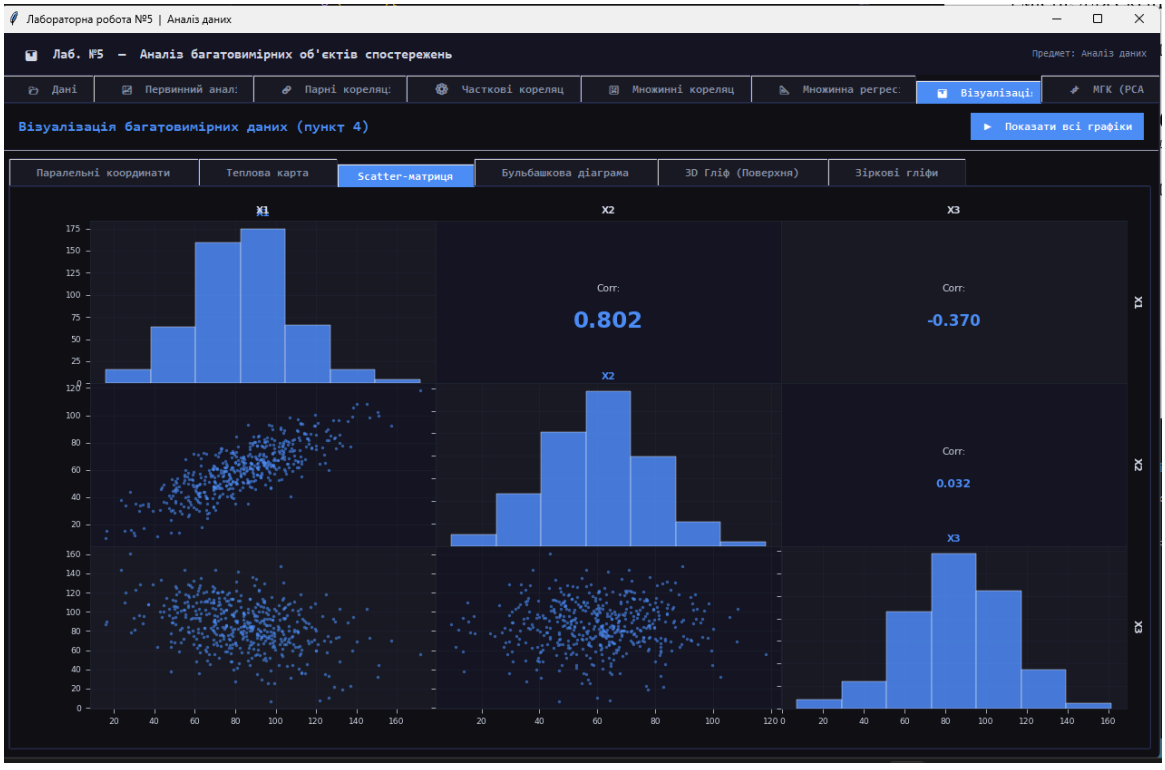


5.4. Візуалізація (Гліфи та 3D моделі)

Реалізовано 3D Гліф для відображення просторової моделі інтенсивності ознак.




Лабораторна робота №5 | Аналіз даних
Лаб. №5 — Аналіз багатовимірних об'єктів спостережень
Предмет: Аналіз даних
Дані
Первинний анал:
Парні кореляц:
Часткові кореляц
Множинні кореляц
Множинна регрес:
Візуалізації
МГК (PCA
Візуалізація багатовимірних даних (пункт 4)
Показати всі графіки
Паралельні координати
Теплова карта
Scatter-матриця
Бульбашкова діаграма
3D Гліф (Поверхня)
Зіркові гліфи
Паралельні координати
175
150
125
100
75
50
25
0
X1
X2
X3


Лабораторна робота №5 | Аналіз даних
Лаб. №5 — Аналіз багатовимірних об'єктів спостережень
Предмет: Аналіз даних
Дані
Первинний анал:
Парні кореляц:
Часткові кореляц
Множинні кореляц
Множинна регрес:
Візуалізації
МГК (PCA
Візуалізація багатовимірних даних (пункт 4)
Показати всі графіки
Паралельні координати
Теплова карта
Scatter-матриця
Бульбашкова діаграма
3D Гліф (Поверхня)
Зіркові гліфи
X1
X2
X3
Corr:
0.802
Corr:
-0.370
Corr:
0.032
X1
X2
X3

6. Висновки

В ході виконання лабораторної роботи було розроблено програмний комплекс для аналізу багатовимірних даних.

Основні результати:

1. Реалізовано методи перевірки статистичних гіпотез, що дозволяють відсіювати нечуттєві зв’язки (через p-value та критерій Фішера).
2. Метод головних компонент продемонстрував можливість стиснення інформації: було визначено, що перші дві компоненти пояснюють значну частину загальної дисперсії, що дозволяє візуалізувати складні структури на площині.
3. Зворотний перехід у МГК підтвердив збереження структури даних при використанні повної системи компонент.
4. Розроблено інтерактивні інструменти візуалізації, які спрощують інтерпретацію багатовимірних об’єктів (бульбашкові діаграми, гліфи).

Програма може бути використана для попередньої обробки даних у задачах машинного навчання та системного аналізу.