

Пункт 1. Знаходження векторів середніх та середньоквадратичних відхилень, матриці значущих парних коефіцієнтів кореляції

1.1. Первинний статистичний аналіз багатовимірних даних (вектор середніх і СКВ)

Знаходження векторів середніх та середньоквадратичних

Вектор математичного сподівання (вектор середніх):

$$\hat{E}\{\tilde{\xi}\} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad \text{де} \quad x_k = \frac{1}{N} \sum_{l=1}^N x_{k,l}, \quad k = 1, \dots, n$$

Вектор середніх показує геометричний центр тяжіння сукупності спостережень у n -вимірному просторі. Це точкова оцінка математичного сподівання багатовимірної випадкової величини ξ .

Оцінка дисперсійно-коваріаційної матриці (ДК-матриця):

$$\hat{D}\{\tilde{\xi}\} = \begin{pmatrix} \hat{\sigma}_1^2 & \hat{\sigma}_1 \hat{\sigma}_2 \hat{r}_{1,2} & \cdots & \hat{\sigma}_1 \hat{\sigma}_n \hat{r}_{1,n} \\ \hat{\sigma}_2 \hat{\sigma}_1 \hat{r}_{2,1} & \hat{\sigma}_2^2 & \cdots & \hat{\sigma}_2 \hat{\sigma}_n \hat{r}_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\sigma}_n \hat{\sigma}_1 \hat{r}_{n,1} & \hat{\sigma}_n \hat{\sigma}_2 \hat{r}_{n,2} & \cdots & \hat{\sigma}_n^2 \end{pmatrix}$$

де незсунена оцінка дисперсії k -ої ознаки:

$$\hat{\sigma}_k^2 = \frac{1}{N-1} \sum_{l=1}^N (x_{k,l} - \bar{x}_k)^2$$

ДК-матриця характеризує розсіювання даних навколо центра тяжіння та лінійні зв'язки між ознаками. Діагональні елементи — дисперсії (середньоквадратичні відхилення в квадраті), позадіагональні — коваріації.

Матриця значущих парних коефіцієнтів кореляції

1.2. Матриця парних коефіцієнтів кореляції (Пірсона)

Повна матриця парних коефіцієнтів кореляції R :

$$\hat{R} = (\hat{r}_{ij}), \quad i, j = 1, \dots, n$$

де

$$\hat{r}_{ij} = \frac{\sum_{l=1}^N (x_{i,l} - \bar{x}_i)(x_{j,l} - \bar{x}_j)}{\sqrt{\sum_{l=1}^N (x_{i,l} - \bar{x}_i)^2 \sum_{l=1}^N (x_{j,l} - \bar{x}_j)^2}}$$

Матриця значущих парних коефіцієнтів кореляції (R_{sig}):

Усі елементи, для яких $|r_{ij}| \leq r_{крит}$, замінюються на 0 (крім діагоналі = 1).

Критичне значення $r_{крит}$ (при рівні значущості α):

$$r_{крит} = \frac{t_{крит}}{\sqrt{N-2 + t_{крит}^2}}$$

де $t_{крит}$ — квантиль t-розподілу Стюдента з $(N-2)$ ступенями свободи.

Перевірка значущості кожної парної кореляції: Статистика:

$$t = \frac{\hat{r}_{ij}\sqrt{N-2}}{\sqrt{1-\hat{r}_{ij}^2}} \sim t(N-2)$$

Якщо $p\text{-value} < \alpha \rightarrow$ кореляція вважається значущою.

Що це означає:

Парний коефіцієнт кореляції вимірює силу та напрямок лінійного зв'язку між двома ознаками. Матриця R_{sig} показує тільки ті зв'язки, які статистично значущі (не є випадковими).

Пункт 2. Перевірка наявності стохастичного зв'язку між ознаками на основі часткових та множинних коефіцієнтів кореляції

Знаходження часткових коефіцієнтів кореляції

2.1. Часткові коефіцієнти кореляції

Рекурентне співвідношення (посібник, стор. 150–151):

Для першого порядку (усунення впливу однієї змінної d):

$$\hat{r}_{i,j \cdot d} = \frac{\hat{r}_{ij} - \hat{r}_{id}\hat{r}_{jd}}{\sqrt{(1-\hat{r}_{id}^2)(1-\hat{r}_{jd}^2)}}$$

Для вищих порядків формула застосовується рекурентно (послідовно виключаються всі інші змінні).

У лабораторній роботі обчислюється часткова кореляція повного порядку ($w = n-2$), тобто усувається вплив усіх інших $(n-2)$ ознак.

Перевірка значущості часткової кореляції:

$$H_0 : r_{i,j \cdot c} = 0$$

Статистика:

$$t = \frac{\hat{r}_{i,j \cdot c}\sqrt{N-w-2}}{\sqrt{1-\hat{r}_{i,j \cdot c}^2}}$$

де w — кількість виключених змінних (порядок часткової кореляції).

Довірчий інтервал (при значущості) — через перетворення Фішера (посібник, стор. 152):

$$v_1 = \frac{1}{2} \ln \left(\frac{1 + \hat{r}}{1 - \hat{r}} \right) - \frac{u_{\alpha/2}}{\sqrt{N - w - 3}}$$

$$v_2 = \frac{1}{2} \ln \left(\frac{1 + \hat{r}}{1 - \hat{r}} \right) + \frac{u_{\alpha/2}}{\sqrt{N - w - 3}}$$

$$\frac{e^{2v_1} - 1}{e^{2v_1} + 1} < r_{i,j;c} < \frac{e^{2v_2} - 1}{e^{2v_2} + 1}$$

Що означає частковий коефіцієнт кореляції:

Він показує «чистий» лінійний зв'язок між двома ознаками після усунення (фіксації) впливу всіх інших ознак. Дозволяє виявляти хибні кореляції (коли зв'язок обумовлений третьою змінною).

2.2. Множинні коефіцієнти кореляції Формула (посібник, стор. 153):

$$\hat{R}_{x_k \cdot (\text{усі інші})} = \sqrt{1 - \frac{|\hat{R}|}{|\hat{R}_{k,k}|}}$$

де

$|R|$ — визначник повної кореляційної матриці $|R_{\{k,k\}}|$ — визначник матриці, отриманої після викреслення k -го рядка і k -го стовпця (мінор)

Перевірка значущості (F-тест):

$$F = \frac{\hat{R}_k^2 (N - n - 1)}{(n)(1 - \hat{R}_k^2)} \sim F(\nu_1 = n - 1, \nu_2 = N - n - 1)$$

Що означає множинний коефіцієнт кореляції:

Він вимірює силу лінійного зв'язку однієї ознаки (x_k) з усіма іншими ознаками одночасно.

R^2_k показує, яка частка дисперсії x_k пояснюється лінійною комбінацією решти ознак.

1. Матриця кореляції (парних коефіцієнтів)

Що таке R (матриця кореляції)? Це квадратна таблиця (матриця), де на перетині i -го рядка і j -го стовпця стоїть коефіцієнт парної кореляції Пірсона r_{ij} між i -ю і j -ю ознаками. На діагоналі завжди 1 (кореляція ознаки самої з собою). Матриця симетрична ($r_{ij} = r_{ji}$). Повна матриця R — показує всі можливі парні зв'язки. Матриця значущих кореляцій (R_{sig}) — у ній не значущі зв'язки замінені на 0 (тільки ті, де $|r| > r_{\text{крит}}$ залишаються).

2. Частковий коефіцієнт кореляції

Скільки штук повинно бути? Якщо в даних p ознак (змінних), то кількість часткових коефіцієнтів = кількість пар = $p(p-1)/2$. Наприклад: 3 ознаки $\rightarrow$ 3 часткові коефіцієнти (X_1 - X_2 , X_1 - X_3 , X_2 - X_3) 4 ознаки $\rightarrow$ 6 часткових коефіцієнтів Не обов'язково exactly 3 — залежить від кількості ознак у твоєму файлі даних.

Чим відрізняється парна кореляція від часткової? Парна (проста) — вимірює зв'язок між двома ознаками без урахування впливу інших. Може бути хибною (спуріозною), якщо обидві ознаки залежать від третьої. Часткова — вимірює «чистий» зв'язок між двома ознаками після усунення (фіксації) впливу всіх інших ознак. Якщо часткова кореляція

близька до нуля, а парна — висока, то зв'язок хибний (обумовлений іншими змінними). Якщо часткова залишається високою — зв'язок справжній.

Кореляція 1 і 2 при контролі інших — означає: наскільки змінюється ознака 1, коли змінюється ознака 2, при умові, що всі інші ознаки тримаємо на постійному рівні (як константу).

3. Значущість ($\alpha = 0.05$)

Що означає $\alpha = 0.05$? Рівень значущості. Ми допускаємо 5% ймовірність помилково відкинути нульову гіпотезу (тобто сказати, що зв'язок є, коли насправді його немає — помилка I роду). Значущість t-тесту Якщо $p\text{-value} < \alpha (0.05)$, то коефіцієнт кореляції (парний чи частковий) вважається статистично значущим — зв'язок не випадковий.

4. Довірчий інтервал (для часткових кореляцій)

Що показує довірчий інтервал (наприклад, 95%)? З ймовірністю 95% справжнє (невідоме) значення часткового коефіцієнта кореляції в генеральній сукупності лежить у цьому інтервалі. Якщо $\alpha = 0.05 \rightarrow$ довірчий інтервал 95% ($1 - \alpha = 0.95$). Він НЕ означає, що ймовірність попадання в інтервал = 0.95 для конкретного розрахунку (інтервал уже побудований). Правильна інтерпретація: «Ми на 95% впевнені, що справжнє значення ρ лежить між нижньою і верхньою межею». Якщо інтервал не містить нуля $\rightarrow$ коефіцієнт значущий. Якщо містить нуль $\rightarrow$ зв'язок може бути відсутнім.

5. Коваріація

Коваріація — це не нормалізована міра спільної варіабельності двох ознак. Коефіцієнт кореляції = коваріація / $(\sigma_1 \times \sigma_2)$ — тому кореляція завжди від -1 до $+1$, а коваріація залежить від одиниць вимірювання.

6. Множинний коефіцієнт кореляції (R_{mult})

Що означає? Показує, наскільки сильно одна ознака (наприклад, X_1) залежить від усіх інших ознак разом (лінійна комбінація). Значення від 0 до 1. Чим ближче до 1 — тим краще інші ознаки пояснюють варіацію даної. R^2 — частка дисперсії, яку пояснюють інші змінні.

7. Інтервальна діаграма (forest plot)

Це графік, де для кожного часткового коефіцієнта показана точка (значення ρ) і горизонтальна лінія — довірчий інтервал. Зелений/червоний колір часто позначає значущий/незначущий. Зручний для візуального порівняння сили та значущості всіх часткових зв'язків.

8. Інтервальне розбиття (гістограми)

Це розбиття осі даних на інтервали (класи) для побудови гістограми. Кількість класів M у твоєму коді обчислюється за формулою посібника ($\sqrt{N}$ або $\sqrt[3]{N}$ залежно від обсягу). Що було б, якби в мене було тільки 10 даних?

Гістограма була б дуже грубою (мало класів). Оцінки (середнє, дисперсія, кореляції) — менш надійними. Довірчі інтервали — дуже широкими. Часткові кореляції високого порядку (при $p=4-5$) могли б бути нестабільними або неможливими через малу кількість ступенів свободи.

Короткі фрази для захисту (можеш зачитувати)

«Парна кореляція показує загальний зв'язок, а часткова — чистий зв'язок після усунення впливу інших ознак.» « $\alpha = 0.05$ означає, що ми допускаємо 5% ризик помилки I роду.» «Довірчий інтервал 95% означає, що з ймовірністю 0.95 справжнє значення коефіцієнта лежить у цих межах.» «Множинний коефіцієнт R_{mult} показує, наскільки одна ознака

залежить від лінійної комбінації всіх інших.» «Якщо довірчий інтервал часткової кореляції не містить нуля — зв'язок значущий.»