

Пункт 1 - 2:

- 1) знаходження векторів середніх та середньоквадратичних, матриці значущих парних коефіцієнтів кореляції (вивести матрицю парних коефіцієнтів кореляції та матрицю значущих парних коефіцієнтів кореляції);
- 2) перевірку наявності стохастичного зв'язку між ознаками об'єкту на основі часткових та множинних коефіцієнтів кореляції: знаходження часткових коефіцієнтів кореляції, перевірка їх значущості; призначення довірчих інтервалів (у випадку значущості); знаходження оцінок коефіцієнтів кореляції; множинні коефіцієнти кореляції.

Пункт 1. Знаходження векторів середніх та середньоквадратичних відхилень, матриці значущих парних коефіцієнтів кореляції

1.1. Первинний статистичний аналіз багатовимірних даних (вектор середніх і СКВ)

Знаходження векторів середніх та середньоквадратичних

Вектор математичного сподівання (вектор середніх):

$$\hat{E}\{\tilde{\xi}\} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad \text{де} \quad x_k = \frac{1}{N} \sum_{l=1}^N x_{k,l}, \quad k = 1, \dots, n$$

Вектор середніх показує геометричний центр тяжіння сукупності спостережень у n -вимірному просторі. Це точкова оцінка математичного сподівання багатовимірної випадкової величини ξ .

Оцінка дисперсійно-коваріаційної матриці (ДК-матриця):

$$\hat{D}\{\tilde{\xi}\} = \begin{pmatrix} \hat{\sigma}_1^2 & \hat{\sigma}_1 \hat{\sigma}_2 \hat{r}_{1,2} & \cdots & \hat{\sigma}_1 \hat{\sigma}_n \hat{r}_{1,n} \\ \hat{\sigma}_2 \hat{\sigma}_1 \hat{r}_{2,1} & \hat{\sigma}_2^2 & \cdots & \hat{\sigma}_2 \hat{\sigma}_n \hat{r}_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{\sigma}_n \hat{\sigma}_1 \hat{r}_{n,1} & \hat{\sigma}_n \hat{\sigma}_2 \hat{r}_{n,2} & \cdots & \hat{\sigma}_n^2 \end{pmatrix}$$

де незсунена оцінка дисперсії k -ої ознаки:

$$\hat{\sigma}_k^2 = \frac{1}{N-1} \sum_{l=1}^N (x_{k,l} - \bar{x}_k)^2$$

ДК-матриця характеризує розсіювання даних навколо центра тяжіння та лінійні зв'язки між ознаками. Діагональні елементи — дисперсії (середньоквадратичні відхилення в квадраті), позадіагональні — коваріації.

Матриця значущих парних коефіцієнтів кореляції

1.2. Матриця парних коефіцієнтів кореляції (Пірсона)

Повна матриця парних коефіцієнтів кореляції R:

$$\hat{R} = (\hat{r}_{ij}), \quad i, j = 1, \dots, n$$

де

$$\hat{r}_{ij} = \frac{\sum_{l=1}^N (x_{i,l} - \bar{x}_i)(x_{j,l} - \bar{x}_j)}{\sqrt{\sum_{l=1}^N (x_{i,l} - \bar{x}_i)^2 \sum_{l=1}^N (x_{j,l} - \bar{x}_j)^2}}$$

Матриця значущих парних коефіцієнтів кореляції (R_sig):

Усі елементи, для яких $|\hat{r}_{ij}| \leq r_{\text{крит}}$, замінюються на 0 (крім діагоналі = 1).

Критичне значення $r_{\text{крит}}$ (при рівні значущості α):

$$r_{\text{крит}} = \frac{t_{\text{крит}}}{\sqrt{N - 2 + t_{\text{крит}}^2}}$$

де $t_{\text{крит}}$ — квантиль t-розподілу Стюдента з $(N-2)$ ступенями свободи.

Перевірка значущості кожної парної кореляції: Статистика:

$$t = \frac{\hat{r}_{ij} \sqrt{N - 2}}{\sqrt{1 - \hat{r}_{ij}^2}} \sim t(N - 2)$$

Якщо $p\text{-value} < \alpha \rightarrow$ кореляція вважається значущою.

Що це означає:

Парний коефіцієнт кореляції вимірює силу та напрямок лінійного зв'язку між двома ознаками. Матриця R_sig показує тільки ті зв'язки, які статистично значущі (не є випадковими).

Пункт 2. Перевірка наявності стохастичного зв'язку між ознаками на основі часткових та множинних коефіцієнтів кореляції

Знаходження часткових коефіцієнтів кореляції

2.1. Часткові коефіцієнти кореляції

Рекурентне співвідношення (посібник, стор. 150–151):

Для першого порядку (усунення впливу однієї змінної d):

$$\hat{r}_{i,j \cdot d} = \frac{\hat{r}_{ij} - \hat{r}_{id}\hat{r}_{jd}}{\sqrt{(1 - \hat{r}_{id}^2)(1 - \hat{r}_{jd}^2)}}$$

Для вищих порядків формула застосовується рекурентно (послідовно виключаються всі інші змінні).

У лабораторній роботі обчислюється часткова кореляція повного порядку ($w = n-2$), тобто усувається вплив усіх інших ($n-2$) ознак.

Перевірка значущості часткової кореляції:

$$H_0 : r_{i,j \cdot c} = 0$$

Статистика:

$$t = \frac{\hat{r}_{i,j \cdot c} \sqrt{N - w - 2}}{\sqrt{1 - \hat{r}_{i,j \cdot c}^2}}$$

де w — кількість виключених змінних (порядок часткової кореляції).

Довірчий інтервал (при значущості) — через перетворення Фішера (посібник, стор. 152):

$$v_1 = \frac{1}{2} \ln \left(\frac{1 + \hat{r}}{1 - \hat{r}} \right) - \frac{u_{\alpha/2}}{\sqrt{N - w - 3}}$$

$$v_2 = \frac{1}{2} \ln \left(\frac{1 + \hat{r}}{1 - \hat{r}} \right) + \frac{u_{\alpha/2}}{\sqrt{N - w - 3}}$$

$$\frac{e^{2v_1} - 1}{e^{2v_1} + 1} < r_{i,j \cdot c} < \frac{e^{2v_2} - 1}{e^{2v_2} + 1}$$

Що означає частковий коефіцієнт кореляції:

Він показує «чистий» лінійний зв'язок між двома ознаками після усунення (фіксації) впливу всіх інших ознак. Дозволяє виявляти хибні кореляції (коли зв'язок обумовлений третьою змінною).

2.2. Множинні коефіцієнти кореляції Формула (посібник, стор. 153):

$$\hat{R}_{x_k \cdot (\text{усі інші})} = \sqrt{1 - \frac{|\hat{R}|}{|\hat{R}_{k,k}|}}$$

де

$|\mathbf{R}|$ — визначник повної кореляційної матриці $|\mathbf{R}_{\{k,k\}}|$ — визначник матриці, отриманої після викреслення k -го рядка і k -го стовпця (мінор)

Перевірка значущості (F-тест):

$$F = \frac{\hat{R}_k^2 (N - n - 1)}{(n)(1 - \hat{R}_k^2)} \sim F(\nu_1 = n - 1, \nu_2 = N - n - 1)$$

Що означає множинний коефіцієнт кореляції:

Він вимірює силу лінійного зв'язку однієї ознаки (x_k) з усіма іншими ознаками одночасно.

R^2_k показує, яка частка дисперсії x_k пояснюється лінійною комбінацією решти ознак.

1. Матриця кореляції (парних коефіцієнтів)

Що таке R (матриця кореляції)? Це квадратна таблиця (матриця), де на перетині i -го рядка і j -го стовпця стоїть коефіцієнт парної кореляції Пірсона r_{ij} між i -ю і j -ю ознаками. На діагоналі завжди 1 (кореляція ознаки самої з собою). Матриця симетрична ($r_{ij} = r_{ji}$). Повна матриця R — показує всі можливі парні зв'язки. Матриця значущих кореляцій (R_{sig}) — у ній не значущі зв'язки замінені на 0 (тільки ті, де $|r| > r_{crit}$ залишаються).

2. Частковий коефіцієнт кореляції

Скільки штук повинно бути? Якщо в даних p ознак (змінних), то кількість часткових коефіцієнтів = кількість пар = $p(p-1)/2$. Наприклад: 3 ознаки $\rightarrow$ 3 часткові коефіцієнти (X_1 - X_2 , X_1 - X_3 , X_2 - X_3) 4 ознаки $\rightarrow$ 6 часткових коефіцієнтів Не обов'язково exactly 3 — залежить від кількості ознак у твоєму файлі даних.

Чим відрізняється парна кореляція від часткової? Парна (проста) — вимірює зв'язок між двома ознаками без урахування впливу інших. Може бути хибною (спуріозною), якщо обидві ознаки залежать від третьої. Часткова — вимірює «чистий» зв'язок між двома ознаками після усунення (фіксації) впливу всіх інших ознак. Якщо часткова кореляція близька до нуля, а парна — висока, то зв'язок хибний (обумовлений іншими змінними). Якщо часткова залишається високою — зв'язок справжній.

Кореляція 1 і 2 при контролі інших — означає: наскільки змінюється ознака 1, коли змінюється ознака 2, при умові, що всі інші ознаки тримаємо на постійному рівні (як константу).

3. Значущість ($\alpha = 0.05$)

Що означає $\alpha = 0.05$? Рівень значущості. Ми допускаємо 5% ймовірність помилково відкинути нульову гіпотезу (тобто сказати, що зв'язок є, коли насправді його немає — помилка I роду). Значущість t-тесту Якщо $p\text{-value} < \alpha$ (0.05), то коефіцієнт кореляції (парний чи частковий) вважається статистично значущим — зв'язок не випадковий.

4. Довірчий інтервал (для часткових кореляцій)

Що показує довірчий інтервал (наприклад, 95%)? З ймовірністю 95% справжнє (невідоме) значення часткового коефіцієнта кореляції в генеральній сукупності лежить у цьому інтервалі. Якщо $\alpha = 0.05 \rightarrow$ довірчий інтервал 95% ($1 - \alpha = 0.95$). Він НЕ означає, що ймовірність попадання в інтервал = 0.95 для конкретного розрахунку (інтервал уже побудований). Правильна інтерпретація: «Ми на 95% впевнені, що справжнє значення ρ лежить між нижньою і верхньою межею». Якщо інтервал не містить нуля $\rightarrow$ коефіцієнт значущий. Якщо містить нуль $\rightarrow$ зв'язок може бути відсутнім.

5. Коваріація

Коваріація — це не нормалізована міра спільної варіабельності двох ознак. Коефіцієнт кореляції = коваріація / ($\sigma_1 \times \sigma_2$) — тому кореляція завжди від -1 до +1, а коваріація залежить від одиниць вимірювання.

6. Множинний коефіцієнт кореляції (R_{mult})

Що означає? Показує, наскільки сильно одна ознака (наприклад, X_1) залежить від усіх інших ознак разом (лінійна комбінація). Значення від 0 до 1. Чим ближче до 1 — тим краще інші ознаки пояснюють варіацію даної. R^2 — частка дисперсії, яку пояснюють інші змінні.

7. Інтервальна діаграма (forest plot)

Це графік, де для кожного часткового коефіцієнта показана точка (значення r) і горизонтальна лінія — довірчий інтервал. Зелений/червоний колір часто позначає значущий/незначущий. Зручний для візуального порівняння сили та значущості всіх часткових зв'язків.

8. Інтервальне розбиття (гістограми)

Це розбиття осі даних на інтервали (класи) для побудови гістограми. Кількість класів M у твоєму коді обчислюється за формулою посібника ($\sqrt{N}$ або $\sqrt[3]{N}$ залежно від обсягу). Що було б, якби в мене було тільки 10 даних?

Гістограма була б дуже грубою (мало класів). Оцінки (середнє, дисперсія, кореляції) — менш надійними. Довірчі інтервали — дуже широкими. Часткові кореляції високого порядку (при $p=4-5$) могли б бути нестабільними або неможливими через малу кількість ступенів свободи.

Короткі фрази для захисту (можеш зачитувати)

«Парна кореляція показує загальний зв'язок, а часткова — чистий зв'язок після усунення впливу інших ознак.» « $\alpha = 0.05$ означає, що ми допускаємо 5% ризик помилки I роду.» «Довірчий інтервал 95% означає, що з ймовірністю 0.95 справжнє значення коефіцієнта лежить у цих межах.» «Множинний коефіцієнт R_{mult} показує, наскільки одна ознака залежить від лінійної комбінації всіх інших.» «Якщо довірчий інтервал часткової кореляції не містить нуля — зв'язок значущий.»

Пункт 3 - 4:

3) за наявності стохастичного зв'язку між ознаками об'єкта відтворення моделі багатовимірної лінійної регресії, що включає:

- знаходження оцінок параметрів регресії та дослідження їх значущості та точності (побудувати інтервальну оцінку параметрів);
- знаходження стандартизованих оцінок параметрів регресії;
- знаходження коефіцієнта детермінації;
- перевірку значущості відтвореної моделі (F-тест);
- побудову толерантних меж (довірчого інтервалу) для залишкової дисперсії;
- побудову довірчих інтервалів для значення регресії;
- побудову діагностичної діаграми.

4) візуалізація багатовимірних даних:

- матриця діаграм розкиду;
- паралельні координати;
- теплова карта;
- бульбашкова діаграма.

3. Відтворення моделі багатовимірної лінійної регресії

Визначення: Багатовимірна лінійна регресія описує лінійну залежність між залежною змінною y та набором незалежних ознак (факторів) $x_1, x_2, \dots, x_k$.

Рівняння моделі:

$$y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + \varepsilon,$$

де β_j — невідомі параметри, а ε — випадкова похибка.

Метод найменших квадратів (МНК):

Використовується для знаходження оцінок параметрів $\hat{\beta}$ шляхом мінімізації суми квадратів залишків. У матричному вигляді:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y},$$

де $\mathbf{X}$ — матриця планового експерименту (з одиничним стовпцем для вільного члена).

Стандартизовані оцінки (Бета-коефіцієнти):

Дозволяють порівняти вплив ознак, що мають різні одиниці вимірювання.

Обчислюються як:

$$\beta_j^* = \hat{\beta}_j \frac{s_{x_j}}{s_y},$$

де s_{x_j} та s_y — середньоквадратичні відхилення відповідних змінних. Чим більше абсолютне значення β_j^* , тим сильніший вплив чинить дана ознака на результат.

Коефіцієнт детермінації (R^2):

Показує частку варіації залежної змінної, яка пояснюється побудованою моделлю.

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}.$$

Значення R^2 знаходиться в межах від 0 до 1; чим воно ближче до 1, тим краща якість моделі.

Перевірка значущості моделі (F-тест):

Перевіряє гіпотезу про те, що всі коефіцієнти регресії (крім вільного члена) дорівнюють нулю.

Якщо $F_{\text{розрах}} > F_{\text{крит}}$, модель вважається статистично значущою.

Інтервальна оцінка параметрів:

Визначає межі, в яких з заданою ймовірністю знаходиться справжнє значення параметра β_j .

Розраховується на основі t -розподілу Стюдента та стандартної похибки коефіцієнта.

Довірчий інтервал для значення регресії:

Оцінює точність передбачення середнього значення y для заданого набору x .

Толерантні межі:

Визначають інтервал, у якому очікується знаходження більшості (наприклад, 95%) окремих спостережень об'єкта. Зазвичай вони ширші за довірчі інтервали для самої лінії регресії.

Діагностична діаграма (аналіз залишків):

Графік, де на осі абсцис відкладаються теоретичні значення $\hat{y}$, а на осі ординат — залишки $e_i = y_i - \hat{y}_i$.

4. Візуалізація багатовимірних даних

Матриця діаграм розкиду (Scatter Plot Matrix):

Це таблиця графіків розмірності $n \times n$. На головній діагоналі зазвичай розміщують гістограми розподілу кожної ознаки, а в інших комірках — парні кореляційні поля (діаграми розкиду) між відповідними ознаками. Це дозволяє миттєво оцінити взаємозв'язки між усіма парами змінних.

Паралельні координати (Parallel Coordinates):

Кожна ознака представлена вертикальною віссю, розташованою паралельно іншим. Одне спостереження відображається як ламана лінія, що з'єднує значення цього об'єкта на кожній з осей. Метод допомагає візуалізувати багатовимірні профілі об'єктів та виявляти закономірності в даних великої вимірності.

Теплова карта (Heatmap):

Матричне представлення даних, де значення в комірках кодуються кольором. Часто використовується для візуалізації кореляційних матриць (де колір вказує на силу зв'язку) або самого масиву даних для виявлення груп схожих об'єктів та ознак.

Бульбашкова діаграма (Bubble Chart):

Нехай потрібно проаналізувати реалізацію ознак X_1 , X_2 та X_3 . Тоді значення перших двох ознак відображають за осями абсцис та ординат, а ознака X_3 відображається пропорційно площі кола. Причому для завдання радіусу R кола використовують відому формулу:

$$R = S/\pi$$